

Smart City

Università degli Studi di Salerno

Giovanni Russo
NF22500029

1 Introduzione

In questo studio è stata progettata, implementata e analizzata una infrastruttura simulata di Federated Learning (Apprendimento Federato) protetta da crittografia omomorfica parziale, applicata alla Computer Vision. L'obiettivo dell'esperimento è stato quello di eseguire una classificazione binaria su immagini di segnaletica stradale (cartelli integri contro cartelli danneggiati) addestrando una rete neurale in maniera distribuita su più nodi, senza che il server centrale possa in alcun momento leggere i parametri che riceve.

Il lavoro svolto ha coperto la costruzione integrale del dataset a partire da una sorgente grezza annotata per il rilevamento, l'introduzione di un'architettura Transformer all'interno di un framework che ne conosceva soltanto di convoluzionali, e l'esecuzione di una campagna sperimentale appaiata di 216 addestramenti federati. È stata testata la rete DeiT-Tiny, un Vision Transformer distillato, in contrapposizione alla ResNet18 impiegata come riferimento dalla letteratura di partenza.

Su entrambe le architetture si è applicata in modo intensivo la tecnica del Transfer Learning: il nucleo di astrazione visiva pre-addestrato è stato congelato per preservare le feature estratte da ImageNet, lasciando in addestramento locale la sola testa di classificazione. Questa scelta non riduce soltanto il carico computazionale e la larghezza di banda: poiché è esattamente la testa l'unico oggetto sottoposto a cifratura, essa determina anche il costo crittografico dell'intero sistema. Da qui discende l'ipotesi che il presente studio verifica.

1.1 Il funzionamento del Federated Learning

- Il server centrale inizializza un modello globale pre-addestrato e ne invia i pesi ai dispositivi client.
- Ogni client addestra localmente il modello utilizzando esclusivamente i dati sensibili presenti nella propria memoria fisica.
- Al termine dell'addestramento locale i client inviano i pesi del modello aggiornato, cifrati.
- Il server raccoglie i contributi e impiega un algoritmo di aggregazione per fonderli, generando un modello globale migliorato, pronto per essere ridistribuito nel round successivo.

1.2 Vantaggi

- Privacy by Design: nessuna immagine sensibile lascia mai il dispositivo fisico del client.
- Efficienza di banda: l'invio esclusivo dei pesi della testa riduce drasticamente il traffico rispetto alla trasmissione di dati grezzi.
- Edge Computing: si decentralizza il carico computazionale sfruttando la potenza di calcolo locale dei dispositivi.

1.3 Problemi

- Eterogeneità (dati Non-IID): i dati locali dei client sono spesso fortemente sbilanciati, condizione che può far divergere i modelli locali compromettendo l'aggregazione globale.
- Limiti computazionali: i dispositivi edge impongono vincoli stringenti di memoria, rendendo preferibili modelli neurali ultra-leggeri.

- Gradient leakage: è il problema su cui questo lavoro si concentra. Il paradigma federato protegge i dati dal trasferimento, ma non protegge l'informazione che essi lasciano impressa nei pesi. Esiste una letteratura consolidata di attacchi capaci di ricostruire le immagini di addestramento a partire dai soli parametri trasmessi. Il server, che è il punto più esposto a compromissione, li riceve da tutti i client a ogni round.

1.4 Le lacune da cui nasce il contributo

Il framework HELM valuta esclusivamente reti convoluzionali: nessun Vision Transformer era mai stato eseguito all'interno dell'architettura cifrata. Parallelamente, il lavoro di tesi dell'anno precedente indica i Transformer come miglior compromesso fra accuratezza e costo, ma li valuta esclusivamente in assenza di crittografia. Le due linee di ricerca non si erano mai incontrate. Infine, tutti e tre i lavori del gruppo insistono sullo stesso dataset da 1.838 immagini, sul quale i modelli raggiungono un F1 pari a 1,0000: un benchmark saturo, privo ormai di potere discriminante fra architetture.

2 Dataset utilizzato

Si è optato per la costruzione integrale del dataset a partire da un progetto pubblico su Roboflow Universe, rilasciato con licenza CC BY 4.0 e successivo a tutti e tre i lavori del gruppo: 12.223 immagini e 16.202 bounding box, prive di augmentation. Il progetto risulta a sua volta contenere la fusione di un dataset denominato Damaged Traffic Signs, versione 3 del 31 gennaio 2026.

La sorgente è annotata per il rilevamento: dichiara dove si trovano i cartelli all'interno di fotografie stradali. Il compito di questo studio è invece la classificazione di un cartello già isolato. La conversione è stata realizzata da uno script che non impiega alcun rilevatore neurale: legge le coordinate normalizzate dai file di etichetta, le converte in pixel e ritaglia. La classe di ogni ritaglio è letta direttamente dall'annotazione.

Primo intervento: rimappatura delle classi

Il file di configurazione dichiarava sette classi. Tre di esse erano righe della documentazione di Roboflow incollate per errore come nomi di categoria, e contenevano complessivamente 12 annotazioni. La quarta anomalia non era invece spuria: recava il titolo del dataset fuso nel progetto e conteneva 1.483 bounding box reali. Un'ispezione visiva a campione ha mostrato che si trattava integralmente di cartelli danneggiati (sostegni piegati, lamiere deformate, ruggine, vernice scrostata) e sono stati pertanto recuperati e assegnati alla classe danneggiata.

Secondo intervento: deduplica e contaminazione fra insiemi

La sorgente conteneva copie identiche e copie ottenute per ribaltamento orizzontale della medesima scena. È stata applicata una deduplica basata su hash percettivo (dHash a 64 bit), resa invariante al ribaltamento adottando come chiave canonica il minimo fra l'hash dell'immagine e quello del suo specchio:

```
canonica(x) = min( dhash(x), dhash(specchio(x)) )
```

Due immagini identiche, o l'una speculare dell'altra, condividono la stessa chiave. Il raggruppamento per chiave individua i duplicati in tempo lineare, senza confronti a coppie.

La politica di rimozione è deliberatamente asimmetrica: i duplicati interni al pool di addestramento sono ridotti a un solo esemplare, mentre le collisioni fra addestramento e test set sono rimosse sempre dall'addestramento e mai dal test, per preservare l'integrità di quest'ultimo.

I 16 conflitti di etichetta rilevati (stessa immagine classificata in entrambe le classi) sono stati segnalati e non rimossi automaticamente.

Il dataset consolidato risulta così composto: 7.100 ritagli di addestramento (4.112 danneggiati (58%) e 2.988 integri (42%)) e 957 ritagli di test indipendente, deduplicati rispetto all'addestramento e mai impiegati durante la campagna sperimentale.

In fase di simulazione federata, al pool consolidato è stato applicato un partizionamento rigoroso tramite l'algoritmo StratifiedKFold. Questo strumento garantisce che la sovrapposizione dei dati assegnati fra un client e l'altro sia matematicamente nulla, condizione imprescindibile per evitare fenomeni di data leakage e certificare l'indipendenza dell'addestramento locale nei nodi.

3 Architetture utilizzate: ResNet18 e DeiT-Tiny

Per operare all'interno di un ecosistema federato composto da dispositivi edge, l'infrastruttura neurale deve rispettare limiti stringenti di memoria e consumo. Nel caso di un sistema cifrato, però, a questi si aggiunge un vincolo ulteriore e dominante: il numero di parametri che devono attraversare lo schema crittografico. Sono state pertanto poste a confronto due architetture rappresentative di due famiglie diverse.

3.1 Perché un Vision Transformer compatto

ResNet18 è una rete convoluzionale residuale del 2015, ed è il riferimento della letteratura di partenza: viene impiegata da tutti e tre i lavori precedenti del gruppo, e la sua conservazione consente di mantenere confrontabili i risultati.

DeiT-Tiny (Data-efficient image Transformer) è una variante distillata di Vision Transformer del 2021. A differenza dei ViT originali, che richiedono dataset di scala industriale per essere addestrati, DeiT introduce una strategia di distillazione che ne rende praticabile l'addestramento su corpora ordinari. Le sue caratteristiche rilevanti in questo contesto sono due: il meccanismo di self-attention, che modella relazioni fra regioni distanti dell'immagine anziché limitarsi a intorni locali come una convoluzione, e soprattutto la dimensione ridotta del vettore di feature prodotto.

	ResNet18	DeiT-Tiny	Rapporto
Famiglia	CNN residuale (2015)	Transformer distillato (2021)	—
Dimensione delle feature	512	192	2,67×
Parametri della testa a 2 layer	131.842	49.922	2,64×
Parametri della testa a 4 layer	172.610	90.690	1,90×

Da qui l'ipotesi falsificabile che l'intero studio verifica: è possibile ridurre di un fattore prossimo a 2,6 il costo della crittografia omomorfica senza perdita di accuratezza, agendo unicamente sulla scelta del backbone e lasciando immutati lo schema crittografico e il protocollo di comunicazione. Non si tratta di un'ottimizzazione implementativa, bensì di una proprietà strutturale dell'architettura.

3.2 Implementazione e Transfer Learning

- Congelamento del feature extractor: tutti i layer interni della rete, precedentemente addestrati sull'immenso dataset ImageNet, sono resi non addestrabili. I loro pesi non vengono più modificati in alcun round, su alcun client, e non vengono mai trasmessi.
- Ricostruzione del classificatore: il layer finale originale, progettato per mille classi, è rimosso e sostituito con una testa densa addestrabile. Sono state valutate due profondità: una testa a 2 layer (512→256→2 per ResNet18) e una a 4 layer (512→256→128→64→2), con ReLU e dropout 0,4 fra gli strati intermedi.

Il congelamento comporta un beneficio collaterale determinante per il federated learning cifrato: ogni client trasmette al server unicamente i parametri della testa finale. Questo abbatta il payload di rete e, soprattutto, riduce nella stessa proporzione il volume di operazioni crittografiche da eseguire.

3.3 Lo schema crittografico di Paillier

Paillier è uno schema di crittografia parzialmente omomorfica: consente due sole operazioni sui dati cifrati, ed entrambe sono esattamente quelle di cui l'aggregazione federata necessita.

- Somma fra ciphertext: il prodotto di due testi cifrati decifra alla somma dei rispettivi valori in chiaro.
- Moltiplicazione per uno scalare in chiaro: consente di pesare il contributo di ciascun client sulla cardinalità del proprio dataset locale.

La divisione non è invece esprimibile. Poiché l'aggregazione federata è una media (una somma divisa per il totale dei campioni) ne discende una conseguenza architettureale rilevante: il server può calcolare unicamente la somma pesata, e la normalizzazione finale viene eseguita dai client dopo la decifratura. Il modello medio non esiste in alcun punto del sistema finché non si materializza all'interno di un client.

4 Design dell'esperimento e Grid Search

Per valutare oggettivamente le prestazioni delle due architetture in contesto federato e cifrato è stata impiegata un'infrastruttura di test completamente automatizzata. Invece di lanciare addestramenti manuali singoli, si è fatto ricorso a una Grid Search orchestrata da file di configurazione, che itera autonomamente su tutte le combinazioni dello spazio di ricerca. Di seguito il frammento relativo allo spazio esplorato.

```
"common_search_space": {
  "encryption_mode":      ["no_encryption"],
  "global_epoch":         [20],
  "local_epoch":          [3],
  "num_clients":           [4, 8, 10],
  "models_percentage":    [1],
  "learning_rate":         [0.01, 0.001, 0.0001],
  "batch_size":            [16],
  "aggregation_algorithm": ["FedAvg", "FedProx", "FedLC"],
  "fedprox_mu":            [0.05]
},
"model_specific_search_space": {
  "ResNet18": { "image_size": [224], "num_custom_layers": [2, 4] },
  "DeiT-Tiny": { "image_size": [224], "num_custom_layers": [2, 4] }
}
```

L'aggiornamento locale dei pesi è delegato all'ottimizzatore Adam, mentre l'entità dell'errore è misurata a ogni epoca tramite la Cross-Entropy Loss. Il valore di `models_percentage` pari a 1 impone che la totalità dei client partecipi a ciascun round, eliminando la partecipazione parziale come variabile confondente.

Incrociando le cinque dimensioni si ottengono 108 configurazioni. Due di esse rispondono alle domande di ricerca mentre le rimanenti tre, algoritmo, learning rate e numero di client, hanno funzione di controllo: servono a verificare che l'eventuale vantaggio osservato sia una proprietà dell'architettura e non l'esito fortunato di una particolare configurazione.

4.1 Ottimizzazione dei client e frazionamento dei dati

Una delle decisioni ingegneristiche più impattanti ha riguardato il numero di nodi da inserire nella simulazione. Nella letteratura classica una rete federata ideale coinvolge centinaia di dispositivi; applicare tale metrica a un pool di 7.100 immagini condurrebbe però a evidenti problemi di instabilità, poiché a ciascun nodo resterebbe una porzione di campioni troppo esigua per costruire gradienti informativi.

Client	Dati per nodo	Addestramento	Validazione locale
4	1.775	1.597	178
8	888	799	89
10	710	639	71
16	444	399	44
32	222	200	22

La simulazione è stata dimensionata su 4, 8 e 10 client. Le prime due configurazioni sono ereditate dallo spazio di ricerca originale del framework, e la loro conservazione mantiene la confrontabilità con i lavori precedenti; la terza è stata aggiunta per estendere la scala di un fattore 2,5. Il limite superiore è determinato dalla dimensione dell'insieme di validazione locale: a 32 client ciascun nodo si valuterebbe su 22 immagini, e un punteggio calcolato su una base tanto ridotta oscillerebbe di diversi punti percentuali per il solo effetto del caso. Si misurerebbe rumore anziché prestazioni. A ciò si aggiunge una ragione di costo, poiché nel blocco cifrato il tempo di esecuzione cresce con il numero di nodi.

4.2 Tecniche di aggregazione

- FedAvg (Federated Averaging): il server calcola la media dei pesi, ponderata sulla cardinalità del dataset posseduto da ciascun client. È l'algoritmo standard e il riferimento del confronto.
- FedProx: introduce nella funzione di perdita locale un termine prossimale che penalizza l'allontanamento del modello locale da quello globale. È progettato per contenere la divergenza fra client in presenza di dati eterogenei.
- FedLC (Federated Logit Calibration): calibra la funzione di perdita in base alla frequenza delle classi, per contrastare lo sbilanciamento nelle distribuzioni locali.

4.3 Esecuzione automatizzata

Il sistema genera l'insieme delle configurazioni e le accoda; un numero configurabile di processi paralleli preleva un lavoro alla volta, lo esegue e ne acquisisce un altro. Prima dell'accodamento, ciascuna configurazione viene confrontata con quelle già presenti nel file dei risultati tramite un'impronta dei propri parametri: le esecuzioni già completate vengono automaticamente saltate. Questo meccanismo di deduplica ha consentito di interrompere e riprendere la campagna in più riprese distinte senza mai ripetere lavoro.

Al termine di ogni ciclo il sistema misura le metriche chiave: Accuratezza, F1-Score, Precision, Recall, Loss. Validandole sulle porzioni locali dei client, e ne salva l'andamento in file CSV per la successiva analisi formale.

4.4 Problematiche riscontrate con la crittografia

Tre limiti dello schema omomorfo sono emersi unicamente in fase di esercizio, e tutti e tre hanno condizionato il disegno operativo della campagna.

Impossibilità di accelerazione su GPU. L'aritmetica di Paillier consiste in esponenziazioni modulari su interi di grande dimensione: non è algebra lineare densa, e non è pertanto esprimibile come kernel CUDA. La libreria gmpy2, che ne implementa il nucleo in C attraverso GMP, opera esclusivamente su CPU.


Impossibilità di parallelizzazione. La misura eseguita sull'ambiente di lavoro mostra una velocità di cifratura sostanzialmente identica con 1, 2 e 4 thread (circa 105.000 operazioni al secondo in tutti i casi) poiché la libreria mantiene il Global Interpreter Lock di Python. Gli N client di una singola esecuzione cifrano dunque in sequenza e non in parallelo, e una esecuzione occupa in pratica un solo core.

Carico termico. Come conseguenza diretta del punto precedente, il calore prodotto dipende dal numero di esecuzioni concorrenti e non dal numero di client. Con dodici esecuzioni in parallelo la CPU (per limiti di infrastruttura) raggiungeva i 95 °C. La campagna definitiva è stata pertanto eseguita vincolando i processi a un sottoinsieme di core fisici, accettando un allungamento del tempo di calendario in cambio di un regime termico sostenibile.

5 Risultati sperimentali

Le metriche finali sono state registrate isolando il completamento del processo di addestramento a 20 epoche globali. La campagna ha prodotto 216 esecuzioni complete, corrispondenti a 108 coppie appaiate.


Nell'esposizione che segue si distingue sistematicamente fra due regimi. Il regime stabile comprende le esecuzioni a learning rate 0,001 e 0,0001, nelle quali l'addestramento converge regolarmente; il regime instabile comprende quelle a learning rate 0,01, nelle quali si manifestano divergenze. La separazione è metodologicamente necessaria: nel secondo regime le differenze di F1 sono dell'ordine di 0,5, ovvero cento volte il segnale che si intende misurare, e la loro inclusione nelle medie le renderebbe prive di significato.



5.1 L'impatto della cifratura sull'accuratezza

Il primo risultato riguarda la domanda preliminare a tutte le altre: la protezione crittografica altera l'esito dell'apprendimento?

Regime stabile, 72 coppie	Media firmata	Media assoluta	Massimo
DeiT-Tiny	-0,00073	0,00341	0,00985
ResNet18	-0,00042	0,00469	0,01544
Complessivo	-0,00057	0,00405	0,01544



Il segno della differenza risulta distribuito simmetricamente: non si osserva alcuna deriva sistematica, ma unicamente il rumore fisiologico della riesecuzione. Il risultato è del resto atteso sul piano teorico, poiché lo schema omomorfico è esatto (la somma dei ciphertext decifra alla somma esatta dei valori in chiaro) e ne costituisce la verifica sperimentale su un dataset e su un backbone mai impiegati in precedenza all'interno di HELM.


5.2 Il confronto fra architetture

Sotto cifratura	F1 medio	F1 max	Dev. std	Divergenze
DeiT-Tiny	0,9332	0,9607	0,035	0 / 54
ResNet18	0,8567	0,9508	0,169	7 / 54

Il divario di quasi otto punti nella media è trainato dalle divergenze. Nel regime in cui entrambi convergono si riduce a 1,44 punti (0,9427 contro 0,9283) praticamente identico al divario misurato in chiaro, 1,47 punti. Sono due affermazioni distinte ed entrambe corrette: la prima riguarda la robustezza, la seconda l'accuratezza.

La dominanza è più netta di quanto la sola media suggerisca. Ordinando per F1 tutte e 216 le esecuzioni della campagna, le prime sedici sono integralmente DeiT-Tiny: la migliore configurazione di ResNet18 occupa la diciassettesima posizione. Fra le prime cinquanta, appena sei appartengono alla rete convoluzionale. Non si tratta quindi di un vantaggio in media, ma di una separazione che si mantiene lungo tutta la graduatoria.

Il terzo asse è il costo, ed è il contributo specifico di questa tesi: a parità di condizioni di esecuzione e di numero di client, sotto cifratura ResNet18 richiede da 1,4 a 1,8 volte il tempo per round di DeiT-Tiny.



Il risparmio misurato, 1,78 volte in media per la testa a 2 layer, risulta inferiore al rapporto fra i parametri, pari a 2,64. La ragione merita di essere esplicitata: il tempo di un round comprende anche l'addestramento, che non si riduce quando si accorcia la testa. Il sovraccosto crittografico segue i parametri; il round nel suo complesso no. È la distanza fra il modello di costo teorico e il comportamento del sistema completo.


Che cosa si intende per divergenza

Il termine indica una condizione precisa e verificabile, non un semplice risultato peggiore: il modello predice la medesima classe per ogni immagine e non apprende più nulla. Nelle 14 esecuzioni interessate l'accuratezza coincide esattamente con la quota della classe maggioritaria nell'insieme di validazione, e l'F1 corrisponde al valore che tale predizione costante produce.

Accuratezza osservata	F1 osservato	F1 atteso predicendo sempre la maggioranza
0,5775	0,4228	0,4228
0,5787	0,4242	0,4243
0,5843	0,4310	0,4310

La soglia di 0,60 adottata per classificare un'esecuzione come divergente non è arbitraria. Ordinando gli F1 di tutte le esecuzioni, il salto più ampio dell'intera distribuzione separa 0,4310 da 0,7482: nell'intervallo intermedio non cade alcuna esecuzione. Quattordici stanno al di sotto, duecentodue al di sopra, e qualunque soglia interna a quel vuoto produce la medesima classificazione. Non si osserva dunque un continuo di prestazioni degradanti, ma due stati distinti e separati. Delle 14 divergenze, tutte appartengono a ResNet18, sette in chiaro e sette cifrate.

5.3 La profondità della testa di classificazione



L'esito è netto e va in direzione contraria all'intuizione comune secondo cui una testa più capiente apprenda meglio. Su DeiT-Tiny la differenza è indistinguibile dal rumore; su ResNet18 la testa profonda è leggermente peggiore. In compenso essa comporta un aumento dell'82% delle cifrature su DeiT-Tiny, da 49.922 a 90.690, e del 31% su ResNet18.

5.4 L'impatto degli algoritmi di aggregazione

Nel regime stabile i tre algoritmi risultano statisticamente equivalenti, con F1 medi compresi fra 0,934 e 0,938 e differenze interne al rumore di riesecuzione. La separazione emerge unicamente in condizioni di stress.

Learning rate 0,01	Esecuzioni	F1 medio	F1 minimo	Divergenze
FedAvg	24	0,7448	0,4228	8
FedLC	24	0,7894	0,4228	6
FedProx	24	0,9182	0,8767	0

Il termine prossimale di FedProx ancora i pesi locali al modello globale e ne impedisce la fuga. È essenziale osservare che FedProx non migliora l'accuratezza: la sua funzione è di stabilizzazione, e si manifesta esclusivamente quando le condizioni di addestramento sono avverse.

5.5 Il costo computazionale della privacy

Il costo è stato misurato normalizzando le durate sul numero di round effettivamente eseguiti, così da neutralizzare l'effetto dell'arresto anticipato. La campagna è completa, con 108 esecuzioni in chiaro e 108 cifrate, e l'analisi dell'accuratezza impiega tutte le coppie. Per il tempo, però, il rapporto calcolato coppia per coppia non è una misura affidabile, e la ragione va esplicitata.

Su tutte le 108 coppie quel rapporto vale in media 2,71 volte, ma in 16 coppie l'esecuzione cifrata risulta più veloce di quella in chiaro. È un esito impossibile, poiché la cifratura aggiunge lavoro senza sottrarne. La causa è la variabilità delle misure in chiaro, raccolte in finestre di esecuzione disturbate dal carico termico e dalla contesa fra processi paralleli: la medesima configurazione di DeiT-Tiny a 8 client ha richiesto fra 24 e 65 secondi per round. Le misure cifrate sono sensibilmente più stabili, con una deviazione standard mediana di 1,9 secondi contro 5,9.

Il costo è stato quindi stimato per carico computazionale, definito da backbone, profondità della testa e numero di client. Per ogni carico si sono raggruppate le nove esecuzioni che lo condividono, dato che algoritmo e learning rate non modificano il lavoro svolto in un round. Come stima dell'esecuzione non disturbata si è adottato il tempo minimo di ciascun carico, criterio consueto nella misura delle prestazioni. Sono stati esclusi i carichi a 4 client, per i quali manca una misura pulita su uno dei due lati:

- per DeiT-Tiny tutte le esecuzioni in chiaro ricadono nella finestra disturbata;
- per ResNet18 tutte quelle cifrate appartengono alla prima sessione, nella quale le esecuzioni cifrate a 8 client sono risultate 1,5 volte più lente delle equivalenti della seconda.

5.6 Generalizzazione su test set indipendente

L'F1 riportato per ciascuna esecuzione è il massimo osservato lungo i venti round, misurato sulle porzioni di validazione locali dei client. Si tratta di una selezione operata sui medesimi dati impiegati per la misura, e come tale ottimisticamente distorta per costruzione. È precisamente per questa ragione che è stato mantenuto un test set indipendente, deduplicato rispetto all'addestramento e mai impiegato durante la campagna.

6 Conclusioni

Lo studio condotto ha dimostrato la fattibilità e la convenienza dell'impiego di un Vision Transformer compatto all'interno di sistemi di Federated Learning protetti da crittografia omomorfica, applicati alla Computer Vision per la manutenzione della segnaletica stradale.

Il risultato principale è che DeiT-Tiny risulta preferibile a ResNet18 su tutti e tre gli assi di valutazione simultaneamente: è più accurato di 1,44 punti di F1 nel regime in cui entrambe le architetture convergono; non diverge mai, contro le 7 divergenze su 54 esecuzioni della controparte convoluzionale; e richiede da 1,4 a 1,8 volte meno tempo per round sotto cifratura. È un esito non ovvio, poiché nella pratica corrente accuratezza e leggerezza sono termini in conflitto.

Il vantaggio di costo non dipende dallo schema crittografico bensì dalla dimensione delle feature prodotte dal backbone: costituisce pertanto una leva di progetto disponibile a chiunque adotti l'approccio del transfer learning federato, e non un'ottimizzazione implementativa legata a questo specifico sistema.

La crittografia omomorfica si è confermata pienamente compatibile con l'accuratezza: su 108 coppie appaiate la differenza media è di sei decimillesimi, e 70 coppie su 72 nel regime stabile si collocano entro un punto percentuale. Il prezzo della privacy è dunque interamente computazionale, ed è precisamente su quel prezzo che la scelta architetturale interviene.

Un ulteriore esito, contrario all'intuizione, riguarda la profondità della testa di classificazione: due layer risultano sufficienti. Quattro non aggiungono accuratezza, comportano fino all'82% di cifrature in più e moltiplicano per sei le divergenze sull'architettura convoluzionale. Nella progettazione di un sistema federato cifrato, la testa va mantenuta poco profonda.

Infine, il dataset costruito per questo studio è pari a 3,9 volte quello impiegato dai lavori precedenti e dispone di un test set indipendente, condizione che ha permesso per la prima volta all'interno di questa linea di ricerca di formulare affermazioni verificate sulla capacità di generalizzazione del modello.

